

Đồ án cuối kỳ

Project 2 - CDC Diabetes Health Indicators

Nhóm 11

2025-01-13

Library

```
library(tidyverse)
library(ggplot2)
library(gridExtra)
library(themis)
library(caret)
library(dplyr)
library(lmPerm)
library(corrplot)
```

I. Load Dataset

```
data <- read_csv(file = 'diabetes_012_health_indicators_BRFSS2015.csv') |> janitor::clean_names()
```

II. EDA

Explore Dataset

```
glimpse(data)
```

```
## Rows: 253,680
## Columns: 22
## $ diabetes_012      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 2, 0, 2, 0, 0, 2, 0, 0,...
## $ high_bp           <dbl> 1, 0, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 0, 1, 0, 1,...
## $ high_chol         <dbl> 1, 0, 1, 0, 1, 1, 0, 1, 1, 0, 0, 1, 0, 1, 1, 0,...
## $ chol_check        <dbl> 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
## $ bmi               <dbl> 40, 25, 28, 27, 24, 25, 30, 25, 30, 24, 25, 34,...
## $ smoker            <dbl> 1, 1, 0, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 0,...
## $ stroke            <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0,...
## $ heart_diseaseor_attack <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0,...
## $ phys_activity     <dbl> 0, 1, 0, 1, 1, 1, 0, 1, 0, 0, 1, 0, 0, 0, 1, 1,...
## $ fruits            <dbl> 0, 0, 1, 1, 1, 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0,...
## $ veggies           <dbl> 1, 0, 0, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 0,...
## $ hvy_alcohol_consump <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,...
## $ any_healthcare    <dbl> 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
## $ no_docbc_cost     <dbl> 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0,...
## $ gen_hlth          <dbl> 5, 3, 5, 2, 2, 2, 3, 3, 5, 2, 3, 3, 3, 4, 4, 2,...
## $ ment_hlth         <dbl> 18, 0, 30, 0, 3, 0, 0, 0, 30, 0, 0, 0, 0, 0, 30...
## $ phys_hlth         <dbl> 15, 0, 30, 0, 0, 2, 14, 0, 30, 0, 0, 30, 15, 0,...
## $ diff_walk         <dbl> 1, 0, 1, 0, 0, 0, 0, 1, 1, 0, 0, 1, 0, 1, 0, 0,...
## $ sex               <dbl> 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0,...
## $ age               <dbl> 9, 7, 9, 11, 11, 10, 9, 11, 9, 8, 13, 10, 7, 11...
## $ education         <dbl> 4, 6, 4, 3, 5, 6, 6, 4, 5, 4, 6, 5, 5, 4, 6, 6,...
## $ income            <dbl> 3, 1, 8, 6, 4, 8, 7, 4, 1, 3, 8, 1, 7, 6, 2, 8,...
```

Clean Dataset

- Kiểm tra dữ liệu có bị NA hay không

```
sum(is.na(data))
```

```
## [1] 0
```

- Kiểm tra và xử lý dữ liệu bị trùng

```
sum(duplicated(data))
```

```
## [1] 23899
```

```
data_diabete <- unique(data)
sum(duplicated(data_diabete))
```

```
## [1] 0
```

Preprocessing & Visualization

Preprocessing

```
#Các biến nhị phân (0, 1)
for (col in names(data_diabete)) {
  if (all(data_diabete[[col]] %in% c(0, 1))) {
    data_diabete[[col]] <- factor(data_diabete[[col]])
  }
}

#Các biến thang đo
data_diabete <- data_diabete |> mutate(gen_hlth = factor(gen_hlth))
data_diabete <- data_diabete |> mutate(age = factor(age))

#Biến tiêu đường
data_diabete <- data_diabete |> mutate(diabetes_012 = factor(diabetes_012))
```

```
cor(data_diabete[, sapply(data_diabete, is.numeric)], use = "complete.obs")
```

```
##               bmi   ment_hlth  phys_hlth  education    income
## bmi           1.00000000  0.06865296  0.1028439 -0.07456774 -0.06919217
## ment_hlth     0.06865296  1.00000000  0.3403616 -0.07642147 -0.18595253
## phys_hlth     0.10284389  0.34036159  1.00000000 -0.12799744 -0.24120987
## education    -0.07456774 -0.07642147 -0.1279974  1.00000000  0.41935368
## income       -0.06919217 -0.18595253 -0.2412099  0.41935368  1.00000000
```

```
data_diabete <- data_diabete |> mutate( education = factor( education ))
data_diabete <- data_diabete |> mutate(income = factor(income))
```

```
glimpse(data_diabete)
```

```
## Rows: 229,781
## Columns: 22
## $ diabetes_012      <fct> 0, 0, 0, 0, 0, 0, 0, 0, 2, 0, 2, 0, 0, 2, 0, 0,...
## $ high_bp           <fct> 1, 0, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 0, 1, 0, 1,...
## $ high_chol         <fct> 1, 0, 1, 0, 1, 1, 0, 1, 1, 0, 0, 1, 0, 1, 1, 0,...
## $ chol_check        <fct> 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
## $ bmi               <dbl> 40, 25, 28, 27, 24, 25, 30, 25, 30, 24, 25, 34,...
## $ smoker            <fct> 1, 1, 0, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 0,...
## $ stroke            <fct> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0,...
## $ heart_diseaseor_attack <fct> 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0,...
## $ phys_activity     <fct> 0, 1, 0, 1, 1, 1, 0, 1, 0, 0, 1, 0, 0, 0, 1, 1,...
## $ fruits            <fct> 0, 0, 1, 1, 1, 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0,...
## $ veggies           <fct> 1, 0, 0, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 0,...
## $ hvy_alcohol_consump <fct> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,...
## $ any_healthcare    <fct> 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
## $ no_docbc_cost     <fct> 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0,...
## $ gen_hlth          <fct> 5, 3, 5, 2, 2, 2, 3, 3, 5, 2, 3, 3, 3, 4, 4, 2,...
## $ ment_hlth         <dbl> 18, 0, 30, 0, 3, 0, 0, 0, 30, 0, 0, 0, 0, 0, 30...
## $ phys_hlth         <dbl> 15, 0, 30, 0, 0, 2, 14, 0, 30, 0, 0, 30, 15, 0,...
## $ diff_walk         <fct> 1, 0, 1, 0, 0, 0, 0, 1, 1, 0, 0, 1, 0, 1, 0, 0,...
## $ sex               <fct> 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0,...
## $ age               <fct> 9, 7, 9, 11, 11, 10, 9, 11, 9, 8, 13, 10, 7, 11...
## $ education         <fct> 4, 6, 4, 3, 5, 6, 6, 4, 5, 4, 6, 5, 5, 4, 6, 6,...
## $ income            <fct> 3, 1, 8, 6, 4, 8, 7, 4, 1, 3, 8, 1, 7, 6, 2, 8,...
```

```
sapply(data_diabete, function(x) length(unique(x)))
```

```
##          diabetes_012          high_bp          high_chol
##                3                2                2
##          chol_check          bmi          smoker
##                2                84                2
##          stroke heart_diseaseor_attack          phys_activity
##                2                2                2
##          fruits          veggies          hvy_alcohol_consump
##                2                2                2
##          any_healthcare          no_docbc_cost          gen_hlth
##                2                2                5
##          ment_hlth          phys_hlth          diff_walk
##                31                31                2
##          sex          age          education
##                2                13                6
##          income
##                8
```

```

data_summary <- data_diabete |>
  dplyr::select(where(is.numeric)) |> # Lọc chỉ các biến định lượng
  summarise(
    across(
      everything(),
      list(
        gttn = ~min(., na.rm = TRUE),
        gtln = ~max(., na.rm = TRUE),
        tv = ~median(., na.rm = TRUE),
        tb = ~mean(., na.rm = TRUE),
        dlc = ~sd(., na.rm = TRUE),
        iqr = ~IQR(., na.rm = TRUE)
      )
    )
  ) |>
  pivot_longer(
    cols = everything(),
    names_to = c("bien", "tk"),
    names_pattern = "^(.*)_(.*)$",
    values_to = "gt"
  ) |>
  pivot_wider(
    names_from = tk,
    values_from = gt
  ) |>
  dplyr::select(bien, gttn, gtln, tv, tb, dlc, iqr)
data_summary

```

```

## # A tibble: 3 × 7
##   bien      gttn  gtln   tv   tb   dlc   iqr
##   <chr>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 bmi          12    98    27 28.7   6.79    8
## 2 ment_hlth     0    30     0  3.51   7.71    2
## 3 phys_hlth     0    30     0  4.68   9.05    4

```

Visualization

– Tổng quan phân phối của các biến

```
# Cài đặt các thư viện cần thiết
renew_df <- data_diabete

cols <- colnames(renew_df)

set.seed(123)
colors <- grDevices::rainbow(length(cols))


plot_list <- list()

for (i in seq_along(cols)) {
  col <- cols[i]
  color <- colors[i]

  p <- ggplot(renew_df, aes_string(x = col)) +
    geom_bar(fill = color, color = "black", alpha = 0.7) +
    labs(title = paste(col, "Distribution")) +
    theme_minimal()


  plot_list[[col]] <- p
}

do.call(grid.arrange, c(plot_list, ncol = 3))
```



– high_bp với diabetes_012

```
#Vẽ biểu đồ kiểm tra những người bị tiểu đường thì huyết áp có cao không
data_diabete|>
  ggplot(aes(x = factor(diabetes_012, levels = c(0, 1, 2),
                        labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")),
            fill = factor(ifelse(high_bp == 1, "High", "Normal")))) +
  geom_bar(stat="count", alpha = 0.8) +
  labs(title = "High BP vs Diabetes",
       x = "",
       y = "",
       fill = "Blood Pressure") +
  theme_minimal()
```



```
table(data_diabete$high_bp, data_diabete$diabetes_012)
```

```
##
##           0           1           2
##  0 114950    1717    8692
##  1  75105    2912   26405
```

Nhận xét


1. Non (0): Cao huyết áp ít hơn người bình thường 39.52%.
2. Pre (1): Cao huyết áp nhiều hơn người bình thường 62,9%.

3. Diabete (2): Cao huyết áp nhiều hơn người bình thường 75,24%.

Vậy, tình trạng cao huyết áp phổ biến ở người tiểu đường và tiền tiểu đường.

– high_chol và diabetes_012

```
#Vẽ biểu đồ kiểm tra những người bị tiểu đường thì có bị cao cholesterol hay không
data_diabete |>
  ggplot(aes(x = factor(diabetes_012, levels = c(0, 1, 2),
                        labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")),
            fill = factor(ifelse(high_chol == 1, "High", "Normal")))) +
  geom_bar(stat="count", alpha = 0.8) +
  labs(title = "High Cholesterol vs Diabetes",
       x = "",
       y = "",
       fill = "High Cholesterol") +
  theme_minimal()
```



```
table(data_diabete$high_chol,data_diabete$diabetes_012)
```

```
##
##      0      1      2
## 0 114917  1755 11601
## 1  75138  2874 23496
```


Nhận xét

1. Non (0): Người có lượng cholesterol cao chiếm khoảng 39,53%.
2. Pre (1): Người có lượng cholesterol cao chiếm khoảng 62,09%.
3. Diabetes (2): Người có lượng cholesterol cao chiếm khoảng 66,95%.

Suy ra, người có lượng cholesterol cao thường là người tiểu đường và tiền tiểu đường.

– smoker với diabetes_012

```
#Vẽ biểu đồ kiểm tra những người bị tiểu đường thì có hút thuốc hay không
data_diabete |>
  ggplot(aes(x = factor(diabetes_012, levels = c(0, 1, 2),
                        labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")),
            fill = factor(ifelse(smoker == 1, "Yes", "No")))) +
  geom_bar(stat="count", alpha = 0.8) +
  labs(title = "Smoker vs Diabetes",
       x = "",
       y = "",
       fill = "smoker") +
  theme_minimal()
```



```
table(data_diabete$smoker, data_diabete$diabetes_012)
```

```
##
##           0           1           2
##    0 103559    2348    16874
##    1  86496    2281    18223
```

Nhận xét


1. Non (0): Người có hút thuốc chiếm khoảng 45,51%.
2. Pre (1): Người có hút thuốc chiếm khoảng 49,28%.
3. Diabete (2): Người có hút thuốc chiếm khoảng 51,92%%.

Tỉ lệ hút thuốc các nhóm không chênh lệch nhiều, suy ra biến `smoker` có thể không ảnh hưởng tới biến mục tiêu.

– `stroke` VỚI `diabetes_012`

```
# Stroke có Liên quan không?
# Vẽ biểu đồ kiểm tra sự Liên quan giữa stroke và diabetes_012
data_diabete |>
  ggplot(aes(x = factor(diabetes_012, levels = c(0, 1, 2),
                        labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")),
            fill = factor(ifelse(stroke == 0, "No", "Yes")))) +
  geom_bar(stat="count", alpha = 0.8) +
  labs(title = "Stroke vs Diabetes",
       x = "",
       y = "",
       fill = "Had Stroke in the past") +
  theme_minimal()
```

Stroke vs Diabetes



```
table(data_diabete$stroke,data_diabete$diabetes_012)
```

```
##
##      0      1      2
## 0 183304  4364 31829
## 1   6751   265  3268
```


Nhận xét

1. Non (0): Người đã từng đột quỵ chiếm khoảng 3,55%.
2. Pre (1): Người đã từng đột quỵ chiếm khoảng 5,72%.
3. Diabete (2): Người đã từng đột quỵ chiếm khoảng 9,31%.

Suy ra, yếu tố đột quỵ dường như không ảnh hưởng đến sự tiểu đường.

— sex với diabetes_012

```
#Sex
#Vẽ biểu đồ kiểm tra liệu giới tính có liên quan tới khả năng mắc bệnh tiểu đường
data_diabete |>
  ggplot(aes(x = factor(diabetes_012, levels = c(0, 1, 2),
                        labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")),
            fill = factor(ifelse(sex == 1, "Male", "Female")))) +
  geom_bar(stat="count", alpha = 0.8) +
  labs(title = "Sex vs Diabetes",
       x = "",
       y = "",
       fill = "Male and Female") +
  theme_minimal()
```



```
table(data_diabete$sex, data_diabete$diabetes_012)
```

```
##
##      0      1      2
## 0 107905  2604 18345
## 1  82150   2025 16752
```

Nhận xét


1. Non (0): Nam chiếm khoảng 43,22%, nữ là 56,78%.
2. Pre (1): Nam chiếm khoảng 43,75%, nữ là 56,25%.

3. Diabetes (2): Nam chiếm khoảng 47,73%%, nữ là 52,27%.

Suy ra, ta thấy số người mắc bệnh tuổi đường ở nữ cao hơn. Nhưng sự chênh lệch tỉ lệ nam và nữ ở các nhóm không nhiều.

– bmi và diabetes_012

```
#BMI
ggplot(data_diabete, aes(x = bmi,color = diabetes_012)) +
  geom_density(alpha = 0.5) +
  labs(title = "Density Plot of BMI by Diabetes ")
```



```
data_diabete_copy <- data_diabete

# Chia các mức chỉ số BMI và thêm vào bản sao
data_diabete_copy$bmi <- cut(data_diabete_copy$bmi,
                             breaks = c(-Inf, 18.5, 24.9, 29.9, 34.9, 39.9, Inf),
                             labels = c("Underweight", "Healthy Weight", "Overweight",
                                         "Obese", "Severely Obese", "Morbidly Obese"),
                             right = FALSE)
```

Nhận xét: từ biểu đồ ta thấy được những người Pre-Diabetes và Diabetes có BMI cao hơn so với những người không mắc bệnh.

```
table(data_diabete_copy$bmi,data_diabete$diabetes_012)
```


```
##
##           0      1      2
## Underweight  2856   28   169
## Healthy Weight 54328 689 3910
## Overweight   70770 1524 10565
## Obese        39257 1315 10193
## Severely Obese 14160  648  5653
## Morbidly Obese  8684  425  4607
```

Nhận xét

- + Người ở nhóm gầy rất ít người bị tiểu đường
 - + Người từ mức thừa cân trở lên nguy cơ bị tiểu đường cao
 - + Người mắc bệnh béo phì có nguy cơ mắc tiểu đường cao gấp 8 lần so với những người có trọng lượng cơ thể bình thường hoặc thậm chí gầy.
- age và diabetes_012

```
q1_data <- data_diabete |>
  group_by(diabetes_012) |>
  summarise(Q1 = quantile(as.numeric(age), 0.25, na.rm = TRUE))

ggplot(data = data_diabete, aes(x = diabetes_012, y = as.numeric(age), fill = diabetes_012)) +
  geom_boxplot() +
  labs(title = "Diabetes Status vs Age", x = "Diabetes_012", y = "Age") +
  scale_fill_manual(values = c("salmon", "lightblue", "forestgreen"), labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")) +
  scale_x_discrete(labels = c("0" = "Non-Diabetes", "1" = "Pre-Diabetes", "2" = "Diabetes")) +
  scale_y_continuous(breaks = seq(0, 20, by = 1)) +
  geom_text(
    data = q1_data,
    aes(x = diabetes_012, y = Q1, label = round(Q1, 1)),
    inherit.aes = FALSE,
    vjust = 1.5,
    hjust = 1.2,
    color = "black"
  )
```




Nhận xét: Càng lớn tuổi nguy cơ mắc bệnh tiểu đường càng cao.

– Người có bệnh nền thì có nguy cơ tiểu đường không?

```
data_diabete|>
  ggplot(aes(x = factor(diabetes_012, levels = c(0, 1, 2),
                        labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")),
            fill = factor(ifelse( heart_diseaseor_attack== 1, "Yes", "No")))) +
  geom_bar(stat="count", alpha = 0.8) +
  labs(title = "Heart diseaseor attack and Diabetes",
       x = "",
       y = "",
       fill = "Yes and No") +
  theme_minimal()
```


Heart diseaseor attack and Diabetes



```
table(data_diabete$heart_diseaseor_attack,data_diabete$diabetes_012)
```

```
##
##      0      1      2
## 0 174858  3965 27241
## 1  15197   664  7856
```

Nhận xét

1. Non (0): Người mắc bệnh tim chiếm khoảng 8%.
2. Pre (1): Người mắc bệnh tim chiếm khoảng 14,34%.
3. Diabete (2): Người mắc bệnh tim chiếm khoảng 22,38%.

=> Theo số liệu ta thấy những người mắc bệnh tim thì có nguy cơ bị tiểu đường cao hơn.

Nhóm đưa ra câu hỏi, **liệu những người cao tuổi và có bệnh nền (bệnh tim) thì có nguy cơ mắc bệnh tiểu đường cao hơn hay không?**

– Kiểm tra câu hỏi


```

diabetes_heart <- subset(data_diabete, diabetes_012 == 2 & heart_diseaseor_attack =
= 1)
group_1 <- nrow(diabetes_heart)
diabetes_heart$age <- diabetes_heart$age

group_2 <- nrow(subset(diabetes_heart, as.numeric(diabetes_heart$age) >= 8))
df <- data.frame(
  Subgroup = c("Heart Diseaseor Attack", "Heart Diseaseor Attack > 55 years old"),
  Count = c(group_1, group_2)
)

ggplot(df, aes(x = "", y = Count, fill = Subgroup)) +
  geom_bar(stat = "identity", width = 0.5, position = position_identity(), alpha =
0.7) +
  labs(
    title = "Diabetes base on heart diseaseor attack and age",
    x = "",
    y = "Count",
    fill = ""
  ) +
  theme_minimal() +
  scale_fill_manual(values = c("Heart Diseaseor Attack" = "darkorange", "Heart Dise
aseor Attack > 55 years old" = "skyblue")) +
  geom_text(aes(label = Count), position = position_stack(vjust = 0.075))


```



Nhận xét: Những người từ 55 tuổi trở lên, mắc bệnh tim và mắc bệnh tiểu đường hơn 89% số người mắc bệnh tim và mắc bệnh tiểu đường.


– diff_walk và diabetes_012

```
data_diabete |>
  ggplot(aes(x = diabetes_012, fill = factor(diff_walk))) +
  geom_bar(position = "dodge") +
  scale_x_discrete(
    labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")
  ) +
  scale_fill_discrete(
    labels = c("No", "Yes")
  ) +
  labs(
    title = "Difficulty Walking vs Diabetes Status",
    x = "Diabetes_012",
    y = "Count",
    fill = "Diff_walk"
  ) +
  theme_minimal()
```



– gen_health và diabetes_012

```
data_diabete |>
  ggplot(aes(x = diabetes_012, fill = gen_hlth)) +
  geom_bar(position = "dodge") +
  scale_x_discrete(
    labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")
  ) +
  scale_fill_discrete(
    labels = c("Excellent", "Very Good", "Good", "Fair", "Poor")
  ) +
  labs(
    title = "Gen Health vs Diabetes Status",
    x = "Diabetes_012",
    y = "Count",
    fill = "Gen_health"
  ) +
  theme_minimal()
```



```
table(data_diabete$gen_hlth, data_diabete$diabetes_012)
```

```
##
##      0      1      2
##  1 33459   313  1135
##  2 70044  1212  6280
##  3 58662  1728 13324
##  4 20740  1025  9781
##  5  7150   351  4577
```


Nhận xét

1. Non (0): Người có sức khỏe trung bình/kém chiếm 14,67%.
2. Pre (1): Người có sức khỏe trung bình/kém chiếm 29,73%.
3. Diabetes (2): Người có sức khỏe trung bình/kém chiếm 40,91%.

=> Người bị tiểu đường có điểm đánh giá sức khỏe chung kém hơn các nhóm còn lại.

– income và diabetes_012


```
ggplot(data = data_diabete, aes(x = diabetes_012, y = as.numeric(income), fill = diabetes_012)) +
  geom_boxplot() +
  labs(title = "Diabetes Status vs Income", x = "Diabetes_012", y = "Income") +
  scale_fill_manual(values = c("salmon", "lightblue", "forestgreen"), labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")) +
  scale_x_discrete(labels = c("0" = "Non-Diabetes", "1" = "Pre-Diabetes", "2" = "Diabetes"))
```



Nhận xét: Người có thu nhập càng cao thì càng ít bị tiểu đường hơn. Vì nhóm người này có cơ hội tiếp xúc với điều kiện sống tốt hơn.

– Tương quan giữa biến education và income cao

```
ggplot(data_diabete, aes(x = education, y = as.numeric(income), fill = education))  
+  
  geom_boxplot() +  
  scale_fill_discrete(  
    labels = c("Never attended school or only kindergarten", "Grades 1 through 8 (E  
lementary)", "Grades 9 through 11 (Some high school)", "Grade 12 or GED (High schoo  
l graduate)", "College 1 year to 3 years (Some college or technical school)", "Coll  
ege 4 years or more (College graduate)")
```



Nhận xét: Người có học vấn càng cao thì có thu nhập càng cao.


- ment_hlth vs phys_hlth

```

data_summary <- data_diabete |>
  gather(key = "Health_Type", value = "Health_Score", phys_hlth, ment_hlth) |>
  group_by(diabetes_012, Health_Type) %>%
  summarise(tb = round(mean(Health_Score, na.rm = TRUE),3), .groups = "drop") |>
  ungroup()

ggplot(data_summary, aes(x = factor(diabetes_012), y = tb, fill = Health_Type)) +
  geom_bar(stat = "identity", position = "dodge") +
  scale_fill_manual(
    values = c("skyblue", "salmon"),
    labels = c("Physical Health", "Mental Health")
  ) +
  labs(
    title = "Health Type vs Diabetes Status",
    x = "Diabetes_012",
    y = "Average",
    fill = "Health Type"
  ) +
  scale_x_discrete(
    labels = c("Non-Diabetes", "Pre-Diabetes", "Diabetes")
  ) +
  theme_minimal() +
  geom_text(
    aes(label = tb),
    position = position_dodge(width = 0.9),
    vjust = -0.5
  )

```


Nhận xét: Theo biểu đồ, số ngày tinh thần/sức khỏe không ổn định trung bình của nhóm người bị tiểu đường luôn cao hơn các nhóm còn lại.

– Các nhóm biến Lifestyle bao gồm: `phys_activity` , `veggies` , `fruits`

```
# Phys_activities
gender_dist <- data_diabete |>
group_by(phys_activity, diabetes_012) |>
summarise(Count = n()) |>
mutate(Percentage = Count / sum(Count) * 100)

ggplot(gender_dist, aes(x = factor(ifelse(phys_activity == 1, "Yes", "No")), y = Percentage, fill = ifelse(diabetes_012 == 2, "Diabetes", ifelse(diabetes_012 == 1, "Pre-Diabetes", "Non-Diabetes")))) +
  geom_bar(stat = "identity", position = "dodge", width = 0.75) +
  geom_text(aes(label = paste0(round(Percentage, 1), "%")),
    position = position_dodge(width = 0.8),
    vjust = -0.5, size = 4) +
  labs(title = "Phys Activity vs Diabetes_012", x = "Phys Activity", y = "Percentage (%)", fill = "Diabetes_012") +
  theme_minimal()
```


Phys Activity vs Diabetes_012



```
# Veggies
gender_dist <- data_diabete %>%
group_by(veggies, diabetes_012) %>%
summarise(Count = n()) %>%
mutate(Percentage = Count / sum(Count) * 100)


ggplot(gender_dist, aes(x = factor(ifelse(veggies== 1,"Yes", "No")), y = Percentag
e, fill = factor(ifelse(diabetes_012==2, "Diabetes",ifelse(diabetes_012 == 1, "Pre-
Diabetes" ,"Non-Diabetes"))))) +
geom_bar(stat = "identity", position = "dodge",width = 0.75) +
geom_text(aes(label = paste0(round(Percentage, 1), "%")),
position = position_dodge(width = 0.8),
vjust = -0.5, size = 4) +
labs(title = "Veggies vs Diabetes_012", x = "Veggies", y = "Percentage (%)", fill =
"Diabetes_012") +
theme_minimal()
```

Veggies vs Diabetes_012



```
# Fruits
gender_dist <- data_diabete %>%
group_by(fruits, diabetes_012) %>%
summarise(Count = n()) %>%
mutate(Percentage = Count / sum(Count) * 100)

ggplot(gender_dist, aes(x = factor(ifelse(fruits== 1,"Yes", "No")), y = Percentage,
fill = factor(ifelse(diabetes_012==2, "Diabetes",ifelse(diabetes_012 == 1, "Pre-Dia
betes" ,"Non-Diabetes"))))) +
geom_bar(stat = "identity", position = "dodge",width = 0.75) +
geom_text(aes(label = paste0(round(Percentage, 1), "%")),
position = position_dodge(width = 0.8),
vjust = -0.5, size = 4) +
labs(title = "Fruits vs Diabetes_012", x = "Fruits", y = "Percentage (%)", fill =
"Diabetes_012") +
theme_minimal()
```



Nhận xét: Những người có lối sống lành mạnh như tham gia hoạt động thể chất, ăn rau xanh và trái cây có thể có tỷ lệ mắc bệnh tiểu đường thấp hơn và tỷ lệ không mắc bệnh cao hơn những người sống thiếu lành mạnh. Điều này cho thấy việc rèn luyện, tham gia hoạt động thể chất, chế độ ăn nhiều rau củ, trái cây chứa nhiều vitamin, giàu chất xơ dường như có ảnh hưởng tích cực đến sức khỏe, giúp giảm nguy cơ mắc bệnh tiểu đường.


– Kiểm tra xem có sự khác biệt đáng kể giữa hai biến Pre-diabete và Diabete thông qua một số biến đặc trưng

```
select_12 <- data_diabete |> filter(!diabetes_012 == 0)
table(select_12['diabetes_012'])
```

```
## diabetes_012
##      0      1      2
##      0 4629 35097
```

```
ggplot(select_12, aes(x = bmi, y = ment_hlth, color = diabetes_012)) +
  geom_point() +
  labs(title = "Scatter plot of BMI vs Mental Health")
```


Scatter plot of BMI vs Mental Health




Histogram of bmi

```
ggplot(select_12, aes(x = bmi, fill = diabetes_012)) +  
  geom_histogram(binwidth = 2, alpha = 0.5, position = "identity") +  
  labs(title = "Distribution of BMI by Diabetes Type")
```

Distribution of BMI by Diabetes Type



```
# Density plot of physical health (phys_hlth)
ggplot(select_12, aes(x = phys_hlth, color = diabetes_012)) +
  geom_density()
```



*Nhận xét:** Thông qua một vài biến đặc trưng thì ta thấy không có sự khác biệt đáng kể giữa hai biến Pre-diabete và Diabete .

II. A/B Testing

```
# Lấy ngẫu nhiên 10% dữ liệu đã cho
set.seed(123)
sample_data <- data_diabete |> sample_frac(0.1) # Lấy 10% dữ liệu
```

- Kiểm tra các biến định tính giả thuyết đặt ra có chính xác hay không

```
set.seed(123)
```

```
resampling_method <- function(data, x, y, R) {  
  contingency_table <- table(data[[x]], data[[y]])  
  ri <- rowSums(contingency_table) # Tổng các quan sát theo dòng  
  cj <- colSums(contingency_table) # Tổng các quan sát theo cột  
  N <- sum(contingency_table)      # Tổng số Lượng quan sát  
  
  Eij <- outer(ri, cj, FUN = "*") / N  
  observed_w <- sum((contingency_table - Eij)^2 / Eij)  
  w_star <- numeric(R)  
  for (r in 1:R) {  
    sample_i <- rep(1:length(ri), ri)  
    sample_j <- sample(sample_i, size = length(sample_i), replace = TRUE)  
    new_contingency_table <- table(sample_i, sample_j)  
    E_star_ij <- outer(rowSums(new_contingency_table), colSums(new_contingency_table), FUN = "*") / N  
    w_star[r] <- sum((new_contingency_table - E_star_ij)^2 / E_star_ij)  
  }  
  
  p_value <- mean(w_star > observed_w)  
  return(p_value)  
}
```

Kiểm tra các biến định tính có độc lập với biến mục tiêu không


```

data_diabete_var <- sample_data |>
select(-c("bmi","ment_hlth","phys_hlth"))

correlation_test <- function(df, target_var) {
  results <- data.frame(
    Variable = character(),
    P_Value = numeric(),
    stringsAsFactors = FALSE
  )

  for (col_name in colnames(df)) {
    if (col_name == target_var) next

    if (is.factor(df[[col_name]]) || is.character(df[[col_name]])) {
      freq_table <- table(df[[target_var]], df[[col_name]])

      test <- resampling_method(data_diabete_var,col_name,target_var,100)

      results <- rbind(results, data.frame(
        Variable = col_name,
        p_value = test
      ))
    }
  }
  results <- results[order(results$p_value), ]

  # Trả về bảng kết quả
  return(results)
}

```

```

# Gọi hàm với dataframe data_diabete và biến mục tiêu diabetes_012
correlation_test(data_diabete_var, "diabetes_012")

```

```
##           Variable p_value
## 1           high_bp      0
## 2           high_chol    0
## 3           chol_check   0
## 4           smoker      0
## 5           stroke       0
## 6 heart_diseaseor_attack 0
## 7           phys_activity 0
## 8           fruits       0
## 9           veggies      0
## 10          hvy_alcohol_consump 0
## 11          any_healthcare 0
## 12          no_docbc_cost 0
## 13          gen_hlth     0
## 14          diff_walk    0
## 15          sex          0
## 16          age         0
## 17          education    0
## 18          income       0
```

Nhận xét: p_value của các biến định tính gần như bằng không. Bác bỏ H_0 , tức là các biến đều có sự phụ thuộc vào biến mục tiêu.

- **Kiểm định ANOVA**

– bmi của 3 nhóm 0, 1, 2 có tương đồng nhau

```
anova_bmi <- aovp(formula = bmi ~ diabetes_012, data = sample_data , perm = "Prob")
# Giảm xuống 1000 lần hoán vị
```

```
## [1] "Settings:  unique SS "
```

```
summary(anova_bmi)
```

```
## Component 1 :
##           Df R Sum Sq R Mean Sq Iter  Pr(Prob)
## diabetes_012    2    48264    24131.9 5000 < 2.2e-16 ***
## Residuals    22975  1058579      46.1
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nhận xét: p_value = 2.2e-16 rất nhỏ.

– ment_hlth của 3 nhóm 0, 1, 2 có tương đồng nhau

```
anova_ment <- aovp(formula = ment_hlth ~ diabetes_012, data = sample_data , perm
="Prob") # Giảm xuống 1000 lần hoán vị
```

```
## [1] "Settings:  unique SS "
```

```
summary(anova_ment)
```

```
## Component 1 :  
##              Df R Sum Sq R Mean Sq Iter  Pr(Prob)  
## diabetes_012    2    4941    2470.4 5000 < 2.2e-16 ***  
## Residuals    22975  1369403      59.6  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nhận xét: p_value = 2.2e-16 rất nhỏ.

– phys_hlth của 3 nhóm 0, 1, 2 có tương đồng nhau

```
anova_phys <- aovp(formula = phys_hlth ~ diabetes_012, data = sample_data , perm  
="Prob") # Giảm xuống 1000 lần hoán vị
```

```
## [1] "Settings:  unique SS "
```

```
summary(anova_phys)
```

```
## Component 1 :  
##              Df R Sum Sq R Mean Sq Iter  Pr(Prob)  
## diabetes_012    2   49154   24577.0 5000 < 2.2e-16 ***  
## Residuals    22975  1846881      80.4  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nhận xét: p_value = 2.2e-16 rất nhỏ.

III. Classification Model

1. Multi-Classification for Non-Pre-Diabetes Prediction


Correlation

Đổi biến diabetes_012 thành diabetes_type

```
data <- data |> rename(diabetes_type = diabetes_012)
data_diabete <- data
corr <- cor(data_diabete[,-1], data_diabete[,1])
corr
```

```
##                diabetes_type
## high_bp          0.27159642
## high_chol        0.20908491
## chol_check       0.06754648
## bmi              0.22437947
## smoker           0.06291410
## stroke           0.10717867
## heart_diseaseor_attack 0.18027169
## phys_activity    -0.12194717
## fruits           -0.04219163
## veggies          -0.05897160
## hvy_alcohol_consump -0.05788191
## any_healthcare    0.01541038
## no_docbc_cost     0.03543569
## gen_hlth          0.30258662
## ment_hlth         0.07350677
## phys_hlth         0.17628674
## diff_walk         0.22423912
## sex              0.03104016
## age              0.18502579
## education         -0.13051692
## income            -0.17148304
```

```
corrplot(cor(data_diabete), method = "color", type = "upper", tl.col = "black")
```



Top 10 biến có tương quan cao nhất với biến mục tiêu `diabetes_type` :

```
top_features <- names(sort(abs(corr[,1]), decreasing = TRUE))[1:10]
top_features
```

```
## [1] "gen_hlth"          "high_bp"          "bmi"
## [4] "diff_walk"         "high_chol"        "age"
## [7] "heart_diseaseor_attack" "phys_hlth"        "income"
## [10] "education"
```

Preprocessing for modeling

Chuyển đổi kiểu dữ liệu của `diabetes_type` thành factor:

```
data_diabete <- data_diabete |> mutate(diabetes_type = factor(diabetes_type, levels  
= c(0,1,2),  
                                  labels = c("Non-diabe  
te",  
                                  "Pre-diabe  
te",  
                                  "Diabet  
e")))
```

Chuyển đổi kiểu dữ liệu của top 10 biến có tương quan cao nhất với biến mục tiêu into factor:

```
data_diabete <- data_diabete |> mutate(gen_hlth = factor(gen_hlth, levels = c(1,2,3,4,5),
labels = c("Excellent",
"Very good",
"Good",
"Fair",
"Poor")))
data_diabete <- data_diabete |> mutate(high_bp = factor(high_bp, levels = c(0,1), labels = c("No", "Yes")))
data_diabete <- data_diabete |> mutate(high_chol = factor(high_chol, levels = c(0,1), labels = c("No", "Yes")))
data_diabete <- data_diabete |> mutate(diff_walk = factor(diff_walk, levels = c(0,1), labels = c("No", "Yes")))
data_diabete <- data_diabete |> mutate(heart_diseaseor_attack = factor(heart_diseaseor_attack, levels = c(0,1), labels = c("No", "Yes")))
data_diabete <- data_diabete |> mutate(age = factor(age, levels = c(1,2,3,4,5,6,7,8,9,10,11,12,13),
labels = c("18-24",
"24-29",
"30-34",
"35-39",
"40-44",
"45-49",
"50-54",
"55-59",
"60-64",
"65-69",
"70-74",
"75-79",
"80-older")))
data_diabete <- data_diabete |> mutate(income = factor(income, levels = c(1,2,3,4,5,6,7,8),
labels = c("Under $10.000",
"$10.000 - $15.000",
"$15.000 - $20.000",
"$20.000 - $25.000",
"$25.000 - $35.000",
"$35.000 - $50.000",
"$50.000 - $75.000",
"Over $75.000")))
data_diabete <- data_diabete |> mutate(education = factor(education, levels = c(1,2,3,4,5,6),
labels = c("Under or Kindergarten",
```

```

Some High School",
"Elementary",
"Secondary and
"High School g
raduate",
"College",
"College gradu
ate"))))

```

Chọn dữ liệu để xây dựng mô hình:

```

selected_data <- data_diabete |> dplyr::select(top_features, diabetes_type)
glimpse(selected_data)

```

```

## Rows: 253,680
## Columns: 11
## $ gen_hlth      <fct> Poor, Good, Poor, Very good, Very good, Very go...
## $ high_bp      <fct> Yes, No, Yes, Yes, Yes, Yes, Yes, Yes, Yes, No,...
## $ bmi          <dbl> 40, 25, 28, 27, 24, 25, 30, 25, 30, 24, 25, 34,...
## $ diff_walk    <fct> Yes, No, Yes, No, No, No, No, Yes, Yes, No, No,...
## $ high_chol    <fct> Yes, No, Yes, No, Yes, Yes, No, Yes, Yes, No, N...
## $ age          <fct> 60-64, 50-54, 60-64, 70-74, 70-74, 65-69, 60-64...
## $ heart_diseaseor_attack <fct> No, No, No, No, No, No, No, No, Yes, No, No, No...
## $ phys_hlth    <dbl> 15, 0, 30, 0, 0, 2, 14, 0, 30, 0, 0, 30, 15, 0,...
## $ income       <fct> $15.000 - $20.000, Under $10.000, Over $75.000,...
## $ education    <fct> High School graduate, College graduate, High Sc...
## $ diabetes_type <fct> Non-diabete, Non-diabete, Non-diabete, Non-diab...

```

```

table(selected_data['diabetes_type'])

```

```

## diabetes_type
## Non-diabete Pre-diabete Diabete
##      213703      4631      35346

```

Train-Test Split:

```

set.seed(123)

min_count <- min(table(selected_data$diabetes_type))
test_size <- round(0.2 * min_count)
TestSet <- selected_data |>
  group_by(diabetes_type) |>
  slice_sample(n = test_size) |>
  ungroup()

TrainSet <- selected_data |> filter(!row_number() %in% row_number(TestSet))

```



```
dim(TrainSet)
```

```
## [1] 250902    11
```

```
print(table(TrainSet["diabetes_type"]))
```

```
## diabetes_type
## Non-diabete Pre-diabete    Diabete
##      211551      4583      34768
```

```
dim(TestSet)
```

```
## [1] 2778    11
```

```
print(table(TestSet["diabetes_type"]))
```

```
## diabetes_type
## Non-diabete Pre-diabete    Diabete
##      926      926      926
```

Build Model

Experiment 1: Multinomial Logistic Regression

With Original Data

```
library(nnet)
out_md_mlogit <- multinom(diabetes_type ~ ., data = TrainSet, maxit = 1000)
```

```
## # weights: 108 (70 variable)
## initial value 275644.020453
## iter 10 value 127449.708006
## iter 20 value 123743.807987
## iter 30 value 119535.655600
## iter 40 value 113731.368514
## iter 50 value 108212.422327
## iter 60 value 105985.436520
## iter 70 value 104601.241543
## iter 80 value 100683.141893
## iter 90 value 100275.067520
## final value 100274.746241
## converged
```

```

pred_mlogit_test <- predict(out_md_mlogit, newdata = TestSet, type = "class")
eval_mlogit_test <- confusionMatrix(data = pred_mlogit_test, reference = TestSet$diabetes_type)
eval_mlogit_test

```

``` ## Confusion Matrix and Statistics ```

```
##
```

```
##
```

```
Reference
```

```
## Prediction Non-diabete Pre-diabete Diabete
```

```
## Non-diabete 902 843 764
```

```
## Pre-diabete 0 0 0
```

```
## Diabete 24 83 162
```

```
##
```

``` ## Overall Statistics ```

```
##
```

```
Accuracy : 0.383
```

```
## 95% CI : (0.3649, 0.4014)
```

```
## No Information Rate : 0.3333
```

```
## P-Value [Acc > NIR] : 2.195e-08
```

```
##
```

```
Kappa : 0.0745
```

```
##
```

```
## McNemar's Test P-Value : < 2.2e-16
```

```
##
```

``` ## Statistics by Class: ```

```
##
```

```
Class: Non-diabete Class: Pre-diabete Class: Diabete
```

```
## Sensitivity 0.9741 0.0000 0.17495
```

```
## Specificity 0.1323 1.0000 0.94222
```

```
## Pos Pred Value 0.3595 NaN 0.60223
```

```
## Neg Pred Value 0.9108 0.6667 0.69550
```

```
## Prevalence 0.3333 0.3333 0.33333
```

```
## Detection Rate 0.3247 0.0000 0.05832
```

```
## Detection Prevalence 0.9032 0.0000 0.09683
```

```
## Balanced Accuracy 0.5532 0.5000 0.55859
```

```
eval_multi_class <- function(x) {
  cc <- sum(diag(x))
  sc <- sum(x)
  pp <- colSums(x)
  tt <- rowSums(x)
  ##
  prec <- diag(x)/colSums(x)
  recall <- diag(x)/rowSums(x)
  macro_prec <- mean(prec)
  macro_recall <- mean(recall)
  macro_f1 <- 2 * macro_prec * macro_recall/(1/macro_prec + 1/macro_recall)
  acc <- cc/sc
  kap <- (cc * sc - sum(pp * tt))/(sc^2 - sum(pp * tt))
  return(list(Precision = prec, Recall = recall, Accuracy = acc, Kappa = kap,
    Macro_F1 = macro_f1))
}
eval_multi_class(table(TestSet$diabetes_type, pred_mlogit_test))
```

```
## $Precision
## Non-diabete Pre-diabete    Diabete
##   0.3595058           NaN    0.6022305
##
## $Recall
## Non-diabete Pre-diabete    Diabete
##   0.9740821    0.0000000    0.1749460
##
## $Accuracy
## [1] 0.3830094
##
## $Kappa
## [1] 0.07451404
##
## $Macro_F1
## [1] NaN
```

Nhận xét: Vì có sự mất cân bằng dữ liệu nên làm cho mô hình không thể dự đoán được các lớp tiền tiểu đường, dẫn đến các chỉ số mô hình bị rỗng.

Kiểm tra số lượng dữ liệu của từng nhãn:

```
table(data_diabete["diabetes_type"])
```

```
## diabetes_type
## Non-diabete Pre-diabete    Diabete
##      213703      4631      35346
```


```

pie_data <- data_diabete |>
  count(diabetes_type) |>
  mutate(percentage = n/sum(n)*100)
pie_db_type <- ggplot(pie_data, aes(x="", y=percentage, fill=diabetes_type)) +
  geom_bar(stat="identity", width=1) +
  coord_polar("y", start=0) +
  theme_bw()

bar_db_type <- ggplot(data_diabete, aes(x=diabetes_type, fill=diabetes_type)) +
  geom_bar() +
  theme_bw()

grid.arrange(pie_db_type, bar_db_type, ncol = 2)

```



Experiment 1.1: With Random Under Sampling:

```

under_sampling <- function(data, name_class){
  new_data <- data
  class_fact <- data[, name_class]
  data_split <- split(data, class_fact)
  n_class <- sapply(data_split, FUN = nrow)
  n_minor <- min(n_class)
  n_major <- max(n_class)
  id_major_class <- which.max(n_class)
  id_minor_class <- which.min(n_class)
  rs_data <- lapply(data_split, function(class_data){
    class_data[sample(1:nrow(class_data), size = n_minor, replace = FALSE),]
  })
  new_data <- do.call(rbind,rs_data)
  return(new_data)
}

```

```

TrainSet_us <- under_sampling(TrainSet,"diabetes_type")
table(TrainSet_us["diabetes_type"])

```

```

## diabetes_type
## Non-diabete Pre-diabete Diabete
##          4583          4583          4583

```

```

out_md_mlogit_us <- multinom(diabetes_type ~ ., data = TrainSet_us, maxit = 1000)

```

```

## # weights: 108 (70 variable)
## initial value 15104.820357
## iter 10 value 13467.707626
## iter 20 value 13308.338013
## iter 30 value 13135.834087
## iter 40 value 13112.442282
## iter 50 value 13093.690103
## iter 60 value 13090.966243
## iter 70 value 13090.524152
## iter 80 value 13089.919784
## final value 13089.910843
## converged

```

```

pred_us <- predict(out_md_mlogit_us, newdata = TestSet, type = "class")
eval_us <- confusionMatrix(data = pred_us, reference = TestSet$diabetes_type)
eval_us

```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Pre-diabete Diabete
## Non-diabete      576         249       144
## Pre-diabete      173         292       252
## Diabete          177         385       530
##
## Overall Statistics
##
##           Accuracy : 0.5032
##           95% CI : (0.4845, 0.522)
## No Information Rate : 0.3333
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.2549
##
## McNemar's Test P-Value : 9.962e-10
##
## Statistics by Class:
##
##           Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity           0.6220           0.3153           0.5724
## Specificity           0.7878           0.7705           0.6965
## Pos Pred Value        0.5944           0.4073           0.4853
## Neg Pred Value        0.8065           0.6924           0.7651
## Prevalence            0.3333           0.3333           0.3333
## Detection Rate        0.2073           0.1051           0.1908
## Detection Prevalence  0.3488           0.2581           0.3931
## Balanced Accuracy      0.7049           0.5429           0.6344
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_us))
```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.5944272    0.4072524    0.4853480
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.6220302    0.3153348    0.5723542
##
## $Accuracy
## [1] 0.5032397
##
## $Kappa
## [1] 0.2548596
##
## $Macro_F1
## [1] 0.1245795
```

Experiment 1.2: With Random Over Sampling:

```
over_sampling <- function(data, name_class){
  new_data <- data
  class_fact <- data[, name_class]
  data_split <- split(data, class_fact)
  n_class <- sapply(data_split, FUN = nrow)
  n_minor <- min(n_class)
  n_major <- max(n_class)
  id_major_class <- which.max(n_class)
  id_minor_class <- which.min(n_class)
  rs_data <- lapply(data_split, function(class_data){
    n <- nrow(class_data)
    if (n < n_major) {
      class_data[sample(1:n, size = n_major, replace = TRUE), ]
    } else {
      class_data
    }
  })
  new_data <- do.call(rbind,rs_data)
  return(new_data)
}
```

```
TrainSet_os <- over_sampling(TrainSet,"diabetes_type")
table(TrainSet_os["diabetes_type"])
```

```
## diabetes_type
## Non-diabete Pre-diabete      Diabete
##      211551      211551      211551
```

```
out_md_mlogit_os <- multinom(diabetes_type ~ ., data = TrainSet_os, maxit = 1000)
```

```
## # weights: 108 (70 variable)
## initial value 697237.584845
## iter 10 value 658406.302149
## iter 20 value 648547.358918
## iter 30 value 647391.579648
## iter 40 value 645292.481888
## iter 50 value 637949.072702
## iter 60 value 629231.401538
## iter 70 value 611028.464737
## iter 80 value 605250.606344
## final value 605249.871268
## converged
```

```
pred_os <- predict(out_md_mlogit_os, newdata = TestSet, type = "class")
eval_os <- confusionMatrix(data = pred_os, reference = TestSet$diabetes_type)
eval_os
```



```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Pre-diabete Diabete
## Non-diabete      583         251      143
## Pre-diabete      178         294      231
## Diabete          165         381      552
##
## Overall Statistics
##
##           Accuracy : 0.5144
##           95% CI : (0.4956, 0.5331)
## No Information Rate : 0.3333
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.2716
##
## Mcnemar's Test P-Value : 5.509e-11
##
## Statistics by Class:
##
##           Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity           0.6296           0.3175           0.5961
## Specificity           0.7873           0.7792           0.7052
## Pos Pred Value        0.5967           0.4182           0.5027
## Neg Pred Value        0.8096           0.6954           0.7774
## Prevalence            0.3333           0.3333           0.3333
## Detection Rate        0.2099           0.1058           0.1987
## Detection Prevalence  0.3517           0.2531           0.3952
## Balanced Accuracy      0.7084           0.5483           0.6506
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_os))
```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.5967247    0.4182077    0.5027322
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.6295896    0.3174946    0.5961123
##
## $Accuracy
## [1] 0.5143988
##
## $Kappa
## [1] 0.2715983
##
## $Macro_F1
## [1] 0.1327445
```

Experiment 1.3: With SMOTE:

```
TrainSet_smote <- smotenc(TrainSet, var = "diabetes_type",
                          k = 10, over_ratio = 1)
table(TrainSet_smote["diabetes_type"])
```

```
## diabetes_type
## Non-diabete Pre-diabete      Diabete
##      211551      211551      211551
```

```
out_md_mlogit_smote <- multinom(diabetes_type ~ ., data = TrainSet_smote, maxit = 1000)
```

```
## # weights:  108 (70 variable)
## initial  value 697237.584845
## iter   10 value 630702.923135
## iter   20 value 619275.964572
## iter   30 value 618157.859351
## iter   40 value 617228.182676
## iter   50 value 616257.194184
## iter   60 value 600854.553917
## iter   70 value 597524.219759
## final   value 596826.929347
## converged
```

```
pred_smote <- predict(out_md_mlogit_smote, newdata = TestSet, type = "class")
eval_smote <- confusionMatrix(data = pred_smote, reference = TestSet$diabetes_type)
eval_smote
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Pre-diabete Diabete
## Non-diabete      569         236      144
## Pre-diabete      210         331      243
## Diabete          147         359      539
##
## Overall Statistics
##
##           Accuracy : 0.518
##           95% CI : (0.4992, 0.5367)
## No Information Rate : 0.3333
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.277
##
## McNemar's Test P-Value : 2.623e-05
##
## Statistics by Class:
##
##           Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity           0.6145           0.3575           0.5821
## Specificity           0.7948           0.7554           0.7268
## Pos Pred Value        0.5996           0.4222           0.5158
## Neg Pred Value        0.8048           0.7016           0.7767
## Prevalence            0.3333           0.3333           0.3333
## Detection Rate        0.2048           0.1192           0.1940
## Detection Prevalence  0.3416           0.2822           0.3762
## Balanced Accuracy      0.7046           0.5564           0.6544
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_smote))
```

```
## $Precision
## Non-diabete Pre-diabete Diabete
## 0.5995785 0.4221939 0.5157895
##
## $Recall
## Non-diabete Pre-diabete Diabete
## 0.6144708 0.3574514 0.5820734
##
## $Accuracy
## [1] 0.5179986
##
## $Kappa
## [1] 0.2769978
##
## $Macro_F1
## [1] 0.1367898
```

Experiment 1.4: Class Weight

```
class_counts <- table(TrainSet$diabetes_type)
class_weights <- nrow(TrainSet) / class_counts
class_weights
```

```
##
## Non-diabete Pre-diabete Diabete
## 1.186012 54.746236 7.216463
```

```
weights <- as.vector(class_weights[TrainSet$diabetes_type])
length(weights)
```

```
## [1] 250902
```

```
out_md_mlogit_w <- multinom(diabetes_type ~ ., data = TrainSet, weights = weights)
```

```
## # weights: 108 (70 variable)
## initial value 826932.061352
## iter 10 value 754089.205703
## iter 20 value 746010.895744
## iter 30 value 744584.418554
## iter 40 value 744080.862570
## iter 50 value 727993.485909
## iter 60 value 724863.814794
## iter 70 value 719767.278175
## final value 717865.250517
## converged
```

```

pred_w <- predict(out_md_mlogit_w, newdata = TestSet, type = "class")
eval_w <- confusionMatrix(data = pred_w, reference = TestSet$diabetes_type)
eval_w

```

Confusion Matrix and Statistics

```

##
##              Reference
## Prediction   Non-diabete Pre-diabete Diabete
## Non-diabete      582       248       145
## Pre-diabete      180       298       229
## Diabete          164       380       552
##

```

Overall Statistics

```

##
##              Accuracy : 0.5155
##              95% CI : (0.4967, 0.5342)
##      No Information Rate : 0.3333
##      P-Value [Acc > NIR] : < 2.2e-16
##

```

```

##              Kappa : 0.2732
##

```

```

## McNemar's Test P-Value : 1.066e-10
##

```

Statistics by Class:

```

##
##              Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity              0.6285              0.3218              0.5961
## Specificity              0.7878              0.7792              0.7063
## Pos Pred Value           0.5969              0.4215              0.5036
## Neg Pred Value           0.8092              0.6968              0.7776
## Prevalence               0.3333              0.3333              0.3333
## Detection Rate           0.2095              0.1073              0.1987
## Detection Prevalence     0.3510              0.2545              0.3945
## Balanced Accuracy        0.7082              0.5505              0.6512

```

```

eval_multi_class(table(TestSet$diabetes_type, pred_w))

```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.5969231    0.4214993    0.5036496
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.6285097    0.3218143    0.5961123
##
## $Accuracy
## [1] 0.5154788
##
## $Kappa
## [1] 0.2732181
##
## $Macro_F1
## [1] 0.1337437
```

Experiment 1.5: Combine UnderSampling with SMOTE

UnderSampling về trung bình số lượng 3 nhóm trong tập dữ liệu, sau đó sử dụng SMOTE để data generation các nhóm có cỡ mẫu thấp hơn về mức trung bình.

```
# Under Sampling
new_data <- TrainSet
class_fact <- TrainSet[, "diabetes_type"]
data_split <- split(TrainSet, class_fact)
n_class <- sapply(data_split, FUN = nrow)
n_major <- max(n_class)
id_major_class <- which.max(n_class)
id_major <- sample(1:n_major, size = mean(nrow(TrainSet)/3), replace = FALSE)
new_data_major <- data_split[[id_major_class]][id_major, ]
new_data <- rbind(data_split[[2]], new_data_major, data_split[[3]])
# SMOTE
TrainSet_cmb <- smotenc(new_data, var = "diabetes_type",
                        k = 5, over_ratio = 1)
table(TrainSet_cmb["diabetes_type"])
```

```
## diabetes_type
## Non-diabete Pre-diabete      Diabete
##          83634          83634          83634
```

```
out_md_mlogit_cmb <- multinom(diabetes_type ~ ., data = TrainSet_cmb, maxit = 1000)
```

```
## # weights: 108 (70 variable)
## initial value 275644.020453
## iter 10 value 247506.578600
## iter 20 value 244452.127166
## iter 30 value 243588.025272
## iter 40 value 242319.028997
## iter 50 value 241742.585878
## iter 60 value 239332.783542
## iter 70 value 237076.561907
## final value 236893.341833
## converged
```

```
pred_cmb <- predict(out_md_mlogit_cmb, newdata = TestSet, type = "class")
eval_cmb <- confusionMatrix(data = pred_cmb, reference = TestSet$diabetes_type)
eval_cmb
```

```
## Confusion Matrix and Statistics
##
##              Reference
## Prediction  Non-diabete Pre-diabete Diabete
## Non-diabete      562         238       143
## Pre-diabete      223         332       247
## Diabete          141         356       536
##
## Overall Statistics
##
##              Accuracy : 0.5148
##              95% CI : (0.496, 0.5335)
##      No Information Rate : 0.3333
##      P-Value [Acc > NIR] : < 2.2e-16
##
##              Kappa : 0.2721
##
##  McNemar's Test P-Value : 0.0001539
##
## Statistics by Class:
##
##              Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity              0.6069              0.3585              0.5788
## Specificity              0.7943              0.7462              0.7316
## Pos Pred Value           0.5960              0.4140              0.5189
## Neg Pred Value           0.8016              0.6994              0.7765
## Prevalence               0.3333              0.3333              0.3333
## Detection Rate           0.2023              0.1195              0.1929
## Detection Prevalence     0.3395              0.2887              0.3719
## Balanced Accuracy        0.7006              0.5524              0.6552
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_cmb))
```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##   0.5959703   0.4139651   0.5188771
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##   0.6069114   0.3585313   0.5788337
##
## $Accuracy
## [1] 0.5147588
##
## $Kappa
## [1] 0.2721382
##
## $Macro_F1
## [1] 0.1343537
```

Experiment 1.6: Combine UnderSampling with OverSampling

```
TrainSet_cmb_os <- over_sampling(new_data, "diabetes_type")
table(TrainSet_cmb_os["diabetes_type"])
```

```
## diabetes_type
## Non-diabete Pre-diabete      Diabete
##           83634           83634           83634
```

```
out_md_mlogit_cmb_os <- multinom(diabetes_type ~ ., data = TrainSet_cmb_os, maxit =
1000)
```

```
## # weights:  108 (70 variable)
## initial  value 275644.020453
## iter   10 value 248341.182406
## iter   20 value 246182.097526
## iter   30 value 245199.950231
## iter   40 value 244687.162236
## iter   50 value 242291.564491
## iter   60 value 241163.579989
## iter   70 value 239930.482949
## final   value 239481.757472
## converged
```



```

pred_cmb_os <- predict(out_md_mlogit_cmb_os, newdata = TestSet, type = "class")
eval_cmb_os <- confusionMatrix(data = pred_cmb_os, reference = TestSet$diabetes_type)
eval_cmb_os

```

```

## Confusion Matrix and Statistics
##
##              Reference
## Prediction  Non-diabete Pre-diabete Diabete
## Non-diabete      579         248       145
## Pre-diabete      176         292       219
## Diabete          171         386       562
##
## Overall Statistics
##
##              Accuracy : 0.5158
##              95% CI : (0.4971, 0.5346)
##      No Information Rate : 0.3333
##      P-Value [Acc > NIR] : < 2.2e-16
##
##              Kappa : 0.2738
##
##  McNemar's Test P-Value : 4.68e-13
##
## Statistics by Class:
##
##              Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity              0.6253              0.3153              0.6069
## Specificity              0.7878              0.7867              0.6992
## Pos Pred Value           0.5957              0.4250              0.5022
## Neg Pred Value           0.8079              0.6968              0.7806
## Prevalence               0.3333              0.3333              0.3333
## Detection Rate           0.2084              0.1051              0.2023
## Detection Prevalence     0.3499              0.2473              0.4028
## Balanced Accuracy        0.7065              0.5510              0.6531

```

```

eval_multi_class(table(TestSet$diabetes_type,pred_cmb_os))

```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.5956790    0.4250364    0.5022341
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.6252700    0.3153348    0.6069114
##
## $Accuracy
## [1] 0.5158387
##
## $Kappa
## [1] 0.2737581
##
## $Macro_F1
## [1] 0.1339996
```

So sánh các chỉ số mô hình của các lần thử nghiệm, ta thấy thí nghiệm thứ năm cho ra chỉ số Macro-F1 và Kappa cao hơn các nhóm còn lại, lần lượt là 0.1343537 và 0.2721382. Như vậy, ta sẽ chọn ra Combine Data, tức là dữ liệu được xử lý mất cân bằng bằng cách kết hợp Undersampling cho nhãn nhiều dữ liệu nhất về trung bình và SMOTE cho hai nhãn còn lại, huấn luyện trên các mô hình khác để tiếp tục kết quả tốt nhất.

Experiment 2: Random Forest with Combine Data

```
library(randomForest)
out_md_RF <- randomForest(diabetes_type ~ ., data = TrainSet_cmb)
```

```
pred_RF <- predict(out_md_RF, newdata = TestSet, type = "class")
eval_RF <- confusionMatrix(data = pred_RF, reference = TestSet$diabetes_type)
eval_RF
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Pre-diabete Diabete
## Non-diabete      700      136      109
## Pre-diabete       69      692       59
## Diabete          157       98      758
##
## Overall Statistics
##
##           Accuracy : 0.7739
##           95% CI : (0.7579, 0.7894)
##           No Information Rate : 0.3333
##           P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.6609
##
## Mcnemar's Test P-Value : 9.444e-09
##
## Statistics by Class:
##
##           Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity      0.7559      0.7473      0.8186
## Specificity      0.8677      0.9309      0.8623
## Pos Pred Value   0.7407      0.8439      0.7483
## Neg Pred Value   0.8767      0.8805      0.9048
## Prevalence       0.3333      0.3333      0.3333
## Detection Rate   0.2520      0.2491      0.2729
## Detection Prevalence 0.3402      0.2952      0.3647
## Balanced Accuracy 0.8118      0.8391      0.8404
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_RF))
```

```
## $Precision
## Non-diabete Pre-diabete    Diabete
##    0.7407407    0.8439024    0.7482725
##
## $Recall
## Non-diabete Pre-diabete    Diabete
##    0.7559395    0.7473002    0.8185745
##
## $Accuracy
## [1] 0.7739381
##
## $Kappa
## [1] 0.6609071
##
## $Macro_F1
## [1] 0.466901
```

Experiment 3: Naive Bayes

```
library(klaR)
out_md_NB <- NaiveBayes(diabetes_type ~ ., data = TrainSet_cmb)
```

```
pred_NB <- predict(out_md_NB, newdata = TestSet)$class
eval_NB <- confusionMatrix(pred_NB, TestSet$diabetes_type)
eval_NB
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction   Non-diabete Pre-diabete Diabete
## Non-diabete      612         295      168
## Pre-diabete      165         298      277
## Diabete          149         333      481
##
## Overall Statistics
##
##           Accuracy : 0.5007
##           95% CI : (0.482, 0.5195)
## No Information Rate : 0.3333
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.2511
##
## McNemar's Test P-Value : 2.438e-09
##
## Statistics by Class:
##
##           Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity              0.6609              0.3218              0.5194
## Specificity              0.7500              0.7613              0.7397
## Pos Pred Value           0.5693              0.4027              0.4995
## Neg Pred Value           0.8156              0.6919              0.7548
## Prevalence               0.3333              0.3333              0.3333
## Detection Rate           0.2203              0.1073              0.1731
## Detection Prevalence     0.3870              0.2664              0.3467
## Balanced Accuracy         0.7055              0.5416              0.6296
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_NB))
```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.5693023    0.4027027    0.4994808
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.6609071    0.3218143    0.5194384
##
## $Accuracy
## [1] 0.5007199
##
## $Kappa
## [1] 0.2510799
##
## $Macro_F1
## [1] 0.1217087
```

Choosing Best Model

Mô hình giải thích tốt nhất tất cả các biến là Random Forest với Combine Data (Undersampling + SMOTE) với kết quả đạt:

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.7407407    0.8439024    0.7482725
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.7559395    0.7473002    0.8185745
##
## $Accuracy
## [1] 0.7739381
##
## $Kappa
## [1] 0.6609071
##
## $Macro_F1
## [1] 0.466901
```

2. Multi-Classification only with Health Indicator

Trong phần này, chúng ta sẽ lọc ra những chỉ số đo lường sức khỏe có mức độ tương quan cao nhất để xây dựng một mô hình chẩn đoán bệnh tiểu đường.

```
top_features
```

```
## [1] "gen_hlth"          "high_bp"          "bmi"
## [4] "diff_walk"        "high_chol"        "age"
## [7] "heart_diseaseor_attack" "phys_hlth"        "income"
## [10] "education"
```

Như trong phần mô tả, các biến sau:

- + gen_hlth: chỉ số đánh giá sức khỏe tổng quát scale từ 1 -> 5, từ rất tốt tới rất tệ
- + high_bp: tình trạng cao huyết áp
- + bmi: chỉ số khối của cơ thể
- + diff_walk: có gặp khó khăn trong việc đi lại hay không
- + high_chol: tình trạng cao cholesterol
- + heart_diseaseor_attack: tiền sử bị các bệnh về tim
- + phys_hlth: sức khỏe tổng quát

được xem như là các chỉ số sức khỏe của con người tại một thời điểm. Ta sẽ chọn các biến này để xem liệu một người có những triệu chứng này có dễ mắc bệnh tiểu đường hơn không.

Multi Logistic Regression

```
out_md_mlogit_hlth <- multinom(diabetes_type ~ gen_hlth + high_bp + bmi + diff_walk  
+ high_chol + heart_diseaseor_attack + phys_hlth,  
data = TrainSet_cmb, maxit = 1000)
```

```
## # weights: 36 (22 variable)  
## initial value 275644.020453  
## iter 10 value 252544.591093  
## iter 20 value 250318.982889  
## final value 243753.742851  
## converged
```

```
pred_hlth <- predict(out_md_mlogit_hlth, newdata = TestSet, type = "class")  
eval_hlth <- confusionMatrix(data = pred_hlth, reference = TestSet$diabetes_type)  
eval_hlth
```

```
## Confusion Matrix and Statistics
##
##               Reference
## Prediction   Non-diabete Pre-diabete Diabete
## Non-diabete      584         269       166
## Pre-diabete      173         269       208
## Diabete          169         388       552
##
## Overall Statistics
##
##               Accuracy : 0.5058
##               95% CI : (0.487, 0.5245)
##       No Information Rate : 0.3333
##       P-Value [Acc > NIR] : < 2.2e-16
##
##               Kappa : 0.2586
##
## Mcnemar's Test P-Value : 3.219e-16
##
## Statistics by Class:
##
##               Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity          0.6307          0.29050          0.5961
## Specificity          0.7651          0.79428          0.6992
## Pos Pred Value       0.5731          0.41385          0.4977
## Neg Pred Value       0.8056          0.69126          0.7759
## Prevalence           0.3333          0.33333          0.3333
## Detection Rate       0.2102          0.09683          0.1987
## Detection Prevalence 0.3668          0.23398          0.3992
## Balanced Accuracy     0.6979          0.54239          0.6477
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_hlth))
```



```
## $Precision
## Non-diabete Pre-diabete Diabete
## 0.5731109 0.4138462 0.4977457
##
## $Recall
## Non-diabete Pre-diabete Diabete
## 0.6306695 0.2904968 0.5961123
##
## $Accuracy
## [1] 0.5057595
##
## $Kappa
## [1] 0.2586393
##
## $Macro_F1
## [1] 0.1252183
```

Random Forest

```
out_md_RF_hlth <- randomForest(diabetes_type ~., data = TrainSet_cmb)
summary(out_md_RF_hlth)
```

```
##           Length Class  Mode
## call              3 -none- call
## type              1 -none- character
## predicted        250902 factor numeric
## err.rate          2000 -none- numeric
## confusion          12 -none- numeric
## votes            752706 matrix numeric
## oob.times         250902 -none- numeric
## classes            3 -none- character
## importance         10 -none- numeric
## importanceSD         0 -none- NULL
## localImportance      0 -none- NULL
## proximity           0 -none- NULL
## ntree              1 -none- numeric
## mtry               1 -none- numeric
## forest            14 -none- list
## y                 250902 factor numeric
## test              0 -none- NULL
## inbag              0 -none- NULL
## terms              3 terms  call
```

```
pred_RF_hlth <- predict(out_md_RF_hlth, newdata = TestSet, type = "class")
eval_RF_hlth <- confusionMatrix(data = pred_RF_hlth, reference = TestSet$diabetes_t
ype)
eval_RF_hlth
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction   Non-diabete Pre-diabete Diabete
## Non-diabete      706         134       108
## Pre-diabete       69         694        62
## Diabete          151          98       756
##
## Overall Statistics
##
##           Accuracy : 0.7761
##           95% CI : (0.7601, 0.7915)
## No Information Rate : 0.3333
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.6641
##
## McNemar's Test P-Value : 7.302e-08
##
## Statistics by Class:
##
##           Class: Non-diabete Class: Pre-diabete Class: Diabete
## Sensitivity           0.7624           0.7495           0.8164
## Specificity           0.8693           0.9293           0.8656
## Pos Pred Value        0.7447           0.8412           0.7522
## Neg Pred Value        0.8798           0.8812           0.9041
## Prevalence            0.3333           0.3333           0.3333
## Detection Rate        0.2541           0.2498           0.2721
## Detection Prevalence  0.3413           0.2970           0.3618
## Balanced Accuracy      0.8159           0.8394           0.8410
```

```
eval_multi_class(table(TestSet$diabetes_type, pred_RF_hlth))
```

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.7447257    0.8412121    0.7522388
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.7624190    0.7494600    0.8164147
##
## $Accuracy
## [1] 0.7760979
##
## $Kappa
## [1] 0.6641469
##
## $Macro_F1
## [1] 0.470444
```

Results

Mô hình chỉ sử dụng các biến liên quan đến chỉ số sức khỏe cho kết quả dự đoán tốt hơn so với mô hình dùng các biến có sự tương quan tốt với biến mục tiêu. Điều đó, cho thấy tình trạng sức khỏe tác động mạnh mẽ lên nguy cơ mắc bệnh.

Mô hình Random Forest với combine data đạt kết quả:

```
## $Precision
## Non-diabete Pre-diabete      Diabete
##    0.7447257    0.8412121    0.7522388
##
## $Recall
## Non-diabete Pre-diabete      Diabete
##    0.7624190    0.7494600    0.8164147
##
## $Accuracy
## [1] 0.7760979
##
## $Kappa
## [1] 0.6641469
##
## $Macro_F1
## [1] 0.470444
```

3. Exploring Pre-diabete class and Diabete class

```
table(data$diabetes_type)
```

```
##
##      0      1      2
## 213703  4631 35346
```

Khi phân ra ba lớp, các mô hình gặp khó khăn trong việc dự đoán tốt các nhãn, do dữ liệu về lớp Pre-diabete quá ít so với hai lớp còn lại. Kể cả khi đi xử lý mất cân bằng dữ liệu, thì các phương pháp dường như đều vướng phải khuyết điểm.

Điều này đưa ta đi đến giả thuyết rằng, **liệu ta có thể tiếp cận bài toán nhị phân chỉ gồm hai nhãn “Non-diabete” và “Diabete” để giúp cho mô hình có thể phán đoán chính xác hơn không?**

Theo kết quả trong phần trực quan, các chỉ số kết quả cho thấy gần như không có sự khác biệt giữa hai nhóm Pre-diabete và Diabete .

4. Binary-Classification for Non-diabete or Diabete

Ý tưởng: Gộp 2 nhóm Pre-Diabete và Diabete thành Diabete nói chung. Sau đó xử lý mất cân bằng dữ liệu bằng cách UnderSampling nhóm Non-diabete về mức ngang tổng của hai nhóm còn lại.

```
data_binary <- data
data_binary$diabetes_type <- ifelse(data_binary$diabetes_type == 0, 0, 1)
glimpse(data_binary)
```

```
## Rows: 253,680
## Columns: 22
## $ diabetes_type      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 0, 1, 0, 0,...
## $ high_bp            <dbl> 1, 0, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 0, 1, 0, 1,...
## $ high_chol          <dbl> 1, 0, 1, 0, 1, 1, 0, 1, 1, 0, 0, 1, 0, 1, 1, 0,...
## $ chol_check         <dbl> 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
## $ bmi                <dbl> 40, 25, 28, 27, 24, 25, 30, 25, 30, 24, 25, 34,...
## $ smoker             <dbl> 1, 1, 0, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 0,...
## $ stroke             <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0,...
## $ heart_diseaseor_attack <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0,...
## $ phys_activity      <dbl> 0, 1, 0, 1, 1, 1, 0, 1, 0, 0, 1, 0, 0, 0, 1, 1,...
## $ fruits             <dbl> 0, 0, 1, 1, 1, 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0,...
## $ veggies           <dbl> 1, 0, 0, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 0,...
## $ hvy_alcohol_consump <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0,...
## $ any_healthcare     <dbl> 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,...
## $ no_docbc_cost      <dbl> 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0,...
## $ gen_hlth           <dbl> 5, 3, 5, 2, 2, 2, 3, 3, 5, 2, 3, 3, 3, 4, 4, 2,...
## $ ment_hlth          <dbl> 18, 0, 30, 0, 3, 0, 0, 0, 30, 0, 0, 0, 0, 0, 30...
## $ phys_hlth          <dbl> 15, 0, 30, 0, 0, 2, 14, 0, 30, 0, 0, 30, 15, 0,...
## $ diff_walk          <dbl> 1, 0, 1, 0, 0, 0, 0, 1, 1, 0, 0, 1, 0, 1, 0, 0,...
## $ sex                <dbl> 0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0,...
## $ age                <dbl> 9, 7, 9, 11, 11, 10, 9, 11, 9, 8, 13, 10, 7, 11...
## $ education          <dbl> 4, 6, 4, 3, 5, 6, 6, 4, 5, 4, 6, 5, 5, 4, 6, 6,...
## $ income             <dbl> 3, 1, 8, 6, 4, 8, 7, 4, 1, 3, 8, 1, 7, 6, 2, 8,...
```

```
table(data_binary$diabetes_type)
```

```
##
##      0      1
## 213703 39977
```

Correlation

```
corr_binary <- cor(data_binary[,-1], data_binary[,1])
corr_binary
```

```
##                                diabetes_type
## high_bp                      0.27033414
## high_chol                    0.21028966
## chol_check                   0.06787860
## bmi                          0.22385070
## smoker                       0.06277766
## stroke                       0.10479970
## heart_diseaseor_attack       0.17693331
## phys_activity                -0.12139187
## fruits                       -0.04208771
## veggies                      -0.05921920
## hvy_alcohol_consump          -0.05668248
## any_healthcare               0.01407923
## no_docbc_cost                0.03802547
## gen_hlth                     0.30078467
## ment_hlth                    0.07497090
## phys_hlth                    0.17494838
## diff_walk                    0.22215489
## sex                          0.02960561
## age                          0.18589120
## education                    -0.13180338
## income                       -0.17279398
```

```
top_features <- names(sort(abs(corr[,1]), decreasing = TRUE))[1:10]
top_features
```

```
## [1] "gen_hlth"          "high_bp"          "bmi"
## [4] "diff_walk"         "high_chol"        "age"
## [7] "heart_diseaseor_attack" "phys_hlth"        "income"
## [10] "education"
```

Không có sự khác biệt với model multi-classification. Sử dụng lại bộ data bên trên.

```
data_binary <- selected_data
data_binary$diabetes_type <- ifelse(data_binary$diabetes_type == "Non-diabete", 0,
1)
data_binary <- data_binary |> mutate(diabetes_type = factor(diabetes_type, levels =
c(0,1),
labels = c("Non-diabet
e",
"Diabete"))))
glimpse(data_binary)
```

```
## Rows: 253,680
## Columns: 11
## $ gen_hlth      <fct> Poor, Good, Poor, Very good, Very good, Very go...
## $ high_bp       <fct> Yes, No, Yes, Yes, Yes, Yes, Yes, Yes, Yes, Yes, No,...
## $ bmi           <dbl> 40, 25, 28, 27, 24, 25, 30, 25, 30, 24, 25, 34,...
## $ diff_walk     <fct> Yes, No, Yes, No, No, No, No, Yes, Yes, No, No,...
## $ high_chol     <fct> Yes, No, Yes, No, Yes, Yes, No, Yes, Yes, No, N...
## $ age           <fct> 60-64, 50-54, 60-64, 70-74, 70-74, 65-69, 60-64...
## $ heart_diseaseor_attack <fct> No, No, No, No, No, No, No, No, Yes, No, No, No...
## $ phys_hlth     <dbl> 15, 0, 30, 0, 0, 2, 14, 0, 30, 0, 0, 30, 15, 0,...
## $ income        <fct> $15.000 - $20.000, Under $10.000, Over $75.000,...
## $ education     <fct> High School graduate, College graduate, High Sc...
## $ diabetes_type <fct> Non-diabete, Non-diabete, Non-diabete, Non-diab...
```

Handling Imbalanced Data

Undersampling Non-diabete về cùng cỡ mẫu với Diabete :

```
under_sampling_2c <- function(data, name_class) {
  class_fact <- as.factor(data[[name_class]])

  data_split <- split(data, class_fact)
  n_class <- sapply(data_split, FUN = nrow)

  n_minor <- min(n_class)
  n_major <- max(n_class)
  id_major_class <- which.max(n_class)
  id_minor_class <- which.min(n_class)

  id_major <- sample(1:n_major, size = n_minor, replace = FALSE)
  new_data_major <- data_split[[id_major_class]][id_major, ]

  new_data <- rbind(data_split[[id_minor_class]], new_data_major)
  return(new_data)
}
set.seed(234)
data_binary <- under_sampling_2c(data_binary, "diabetes_type")
table(data_binary$diabetes_type)
```

```
##
## Non-diabete      Diabete
##           39977      39977
```

Train-test split

```
set.seed(123)
library(caTools)
spl <- sample.split(data_binary$diabetes_type, SplitRatio = 0.8)
TrainSet_binary <- subset(data_binary, spl==TRUE)
TestSet_binary <- subset(data_binary, spl==FALSE)
```

```
table(TestSet_binary$diabetes_type)
```

```
##
## Non-diabete      Diabete
##           7995      7995
```

```
dim(TrainSet_binary)
```

```
## [1] 63964    11
```

```
dim(TestSet_binary)
```

```
## [1] 15990    11
```

Binary Classification Model

Logistic Regression

```
glm_md <- glm(formula = diabetes_type ~ .,
              data = TrainSet_binary, family = binomial)
summary(glm_md)
```



```
##
## Call:
## glm(formula = diabetes_type ~ ., family = binomial, data = TrainSet_binary)
##
## Coefficients:
##
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -5.107316    0.366174  -13.948 < 2e-16
## gen_hlthVery good    0.673486    0.038247   17.609 < 2e-16
## gen_hlthGood      1.352005    0.037967   35.610 < 2e-16
## gen_hlthFair      1.810853    0.044187   40.981 < 2e-16
## gen_hlthPoor      1.936258    0.059017   32.808 < 2e-16
## high_bpYes        0.694570    0.020455   33.956 < 2e-16
## bmi              0.070422    0.001615   43.597 < 2e-16
## diff_walkYes      0.083579    0.026766    3.123 0.001793
## high_cholYes      0.565281    0.019616   28.817 < 2e-16
## age24-29          0.279063    0.158777    1.758 0.078820
## age30-34          0.354432    0.145894    2.429 0.015124
## age35-39          0.892919    0.137577    6.490 8.57e-11
## age40-44          0.991798    0.134678    7.364 1.78e-13
## age45-49          1.302998    0.132433    9.839 < 2e-16
## age50-54          1.480386    0.130716   11.325 < 2e-16
## age55-59          1.550062    0.130047   11.919 < 2e-16
## age60-64          1.798057    0.129703   13.863 < 2e-16
## age65-69          1.984546    0.129689   15.302 < 2e-16
## age70-74          2.099293    0.130537   16.082 < 2e-16
## age75-79          2.022086    0.131843   15.337 < 2e-16
## age80-older       1.925873    0.131750   14.618 < 2e-16
## heart_diseaseor_attackYes 0.329256    0.029455   11.178 < 2e-16
## phys_hlth        -0.003731    0.001264   -2.952 0.003153
## income$10.000 - $15.000    0.028160    0.059239    0.475 0.634528
## income$15.000 - $20.000   -0.098975    0.055794   -1.774 0.076072
## income$20.000 - $25.000   -0.077390    0.054438   -1.422 0.155141
## income$25.000 - $35.000   -0.195425    0.053100   -3.680 0.000233
## income$35.000 - $50.000   -0.295304    0.051806   -5.700 1.20e-08
## income$50.000 - $75.000   -0.295256    0.051743   -5.706 1.16e-08
## incomeOver $75.000      -0.462290    0.050672   -9.123 < 2e-16
## educationElementary    0.111737    0.344360    0.324 0.745576
## educationSecondary and Some High School -0.094208    0.340620   -0.277 0.782104
## educationHigh School graduate -0.246776    0.338317   -0.729 0.465743
## educationCollege      -0.210738    0.338393   -0.623 0.533442
## educationCollege graduate -0.312438    0.338505   -0.923 0.356011
##
## (Intercept)          ***
## gen_hlthVery good    ***
## gen_hlthGood          ***
## gen_hlthFair          ***
## gen_hlthPoor          ***
## high_bpYes            ***
## bmi                    ***
## diff_walkYes          **
```

```

## high_cholYes ***
## age24-29 .
## age30-34 *
## age35-39 ***
## age40-44 ***
## age45-49 ***
## age50-54 ***
## age55-59 ***
## age60-64 ***
## age65-69 ***
## age70-74 ***
## age75-79 ***
## age80-older ***
## heart_diseaseor_attackYes ***
## phys_hlth **
## income$10.000 - $15.000
## income$15.000 - $20.000 .
## income$20.000 - $25.000
## income$25.000 - $35.000 ***
## income$35.000 - $50.000 ***
## income$50.000 - $75.000 ***
## incomeOver $75.000 ***
## educationElementary
## educationSecondary and Some High School
## educationHigh School graduate
## educationCollege
## educationCollege graduate
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 88673  on 63963  degrees of freedom
## Residual deviance: 66750  on 63929  degrees of freedom
## AIC: 66820
##
## Number of Fisher Scoring iterations: 5

```

Kiểm tra đa cộng tuyến

```

library(car)
vif(glm_md)

```

	GVIF	Df	GVIF^(1/(2*Df))
gen_hlth	1.821202	4	1.077816
high_bp	1.130451	1	1.063227
bmi	1.118387	1	1.057538
diff_walk	1.424672	1	1.193596
high_chol	1.060395	1	1.029755
age	1.293884	12	1.010793
heart_diseaseor_attack	1.097419	1	1.047578
phys_hlth	1.684650	1	1.297941
income	1.496878	7	1.029232
education	1.317432	5	1.027952

Không có đa cộng tuyến.


```
glm_pred_prob <- predict(glm_md, newdata = TestSet_binary, type = 'response')
glm_pred <- ifelse(glm_pred_prob >= 0.6, "Diabete", "Non-diabete")
confusionMatrix(as.factor(glm_pred), TestSet_binary$diabetes_type, positive="Non-diabete")
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Diabete
## Non-diabete      6438      2831
## Diabete          1557      5164
##
##           Accuracy : 0.7256
##           95% CI : (0.7186, 0.7325)
## No Information Rate : 0.5
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.4512
##
## McNemar's Test P-Value : < 2.2e-16
##
##           Sensitivity : 0.8053
##           Specificity : 0.6459
##           Pos Pred Value : 0.6946
##           Neg Pred Value : 0.7683
##           Prevalence : 0.5000
##           Detection Rate : 0.4026
##           Detection Prevalence : 0.5797
##           Balanced Accuracy : 0.7256
##
##           'Positive' Class : Non-diabete
##
```

```
library(pROC)
roc_glm <- roc(TestSet_binary$diabetes_type, glm_pred_prob)
auc_glm <- auc(roc_glm)
print(auc_glm)
```

```
## Area under the curve: 0.8113
```

```
plot(roc_glm, legacy.axes=TRUE, main="ROC Curve for Logistic Regression", asp=0, col="forestgreen")
```



Random Forest

```
rf_md <- randomForest(formula = diabetes_type ~., data= TrainSet_binary, ntree=500)
summary(rf_md)
```

##	Length	Class	Mode
## call	4	-none-	call
## type	1	-none-	character
## predicted	63964	factor	numeric
## err.rate	1500	-none-	numeric
## confusion	6	-none-	numeric
## votes	127928	matrix	numeric
## oob.times	63964	-none-	numeric
## classes	2	-none-	character
## importance	10	-none-	numeric
## importanceSD	0	-none-	NULL
## localImportance	0	-none-	NULL
## proximity	0	-none-	NULL
## ntree	1	-none-	numeric
## mtry	1	-none-	numeric
## forest	14	-none-	list
## y	63964	factor	numeric
## test	0	-none-	NULL
## inbag	0	-none-	NULL
## terms	3	terms	call

```
rf_pred_prob <- predict(rf_md, newdata = TestSet_binary, type="prob")
rf_pred <- ifelse(rf_pred_prob[, "Diabete"] > 0.6, "Diabete", "Non-diabete")
confusionMatrix(as.factor(rf_pred), TestSet_binary$diabetes_type, positive = "Non-diabete")
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Diabete
## Non-diabete      6030    2452
## Diabete          1965    5543
##
##           Accuracy : 0.7238
##           95% CI : (0.7168, 0.7307)
## No Information Rate : 0.5
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.4475
##
## Mcnemar's Test P-Value : 2.62e-13
##
##           Sensitivity : 0.7542
##           Specificity : 0.6933
##           Pos Pred Value : 0.7109
##           Neg Pred Value : 0.7383
##           Prevalence : 0.5000
##           Detection Rate : 0.3771
##           Detection Prevalence : 0.5305
##           Balanced Accuracy : 0.7238
##
##           'Positive' Class : Non-diabete
##
```


```
# ROC
roc_rf <- roc(TestSet_binary$diabetes_type, rf_pred_prob[, "Diabete"],
             levels = c("Diabete", "Non-diabete"), direction = ">")

# AUC
auc_rf <- auc(roc_rf)
print(auc_rf)
```

```
## Area under the curve: 0.7969
```

```
plot(roc_rf, legacy.axes=TRUE, main="ROC Curve for Random Forest", col="forestgreen",
     asp=0)
```

ROC Curve for Random Forest



NaiveBayes

```
nb_md <- NaiveBayes(formula = diabetes_type ~ ., data = TrainSet_binary)
summary(nb_md)
```

```
##           Length Class      Mode
## apriori      2      table    numeric
## tables     10     -none-     list
## levels       2     -none-     character
## call         3     -none-     call
## x            10    data.frame list
## usekernel    1     -none-     logical
## varnames     10     -none-     character
```

```
nb_pred_prob <- predict(nb_md, newdata = TestSet_binary, type="raw")$posterior
nb_pred <- ifelse(nb_pred_prob[, "Diabete"] > 0.6, "Diabete", "Non-diabete")
confusionMatrix(as.factor(nb_pred), TestSet_binary$diabetes_type)
```


```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction  Non-diabete Diabete
## Non-diabete      6301    2961
## Diabete          1694    5034
##
##           Accuracy : 0.7089
##           95% CI : (0.7018, 0.7159)
## No Information Rate : 0.5
## P-Value [Acc > NIR] : < 2.2e-16
##
##           Kappa : 0.4178
##
## Mcnemar's Test P-Value : < 2.2e-16
##
##           Sensitivity : 0.7881
##           Specificity : 0.6296
##           Pos Pred Value : 0.6803
##           Neg Pred Value : 0.7482
##           Prevalence : 0.5000
##           Detection Rate : 0.3941
##           Detection Prevalence : 0.5792
##           Balanced Accuracy : 0.7089
##
##           'Positive' Class : Non-diabete
##
```

```
roc_nb <- roc(TestSet_binary$diabetes_type, nb_pred_prob[, "Diabete"],
              levels = c("Diabete", "Non-diabete"), direction = ">")

auc_nb <- auc(roc_nb)
print(auc_nb)
```

```
## Area under the curve: 0.7947
```


```
plot(roc_nb, legacy.axes=TRUE, main = "ROC Curve for Naive Bayes", col = "forestgre
en", asp=0)
```

Conclusion

- Mô hình phân loại nhị phân cho kết quả tốt hơn hẳn so với mô hình phân loại đa biến. Điều này cho thấy mô hình có thể chuẩn đoán tốt giữa Non-diabete và Diabete .
- Mô hình tốt nhất cho bài toán phân loại nhị phân là Logistic Regression với dữ liệu Undersampling. Kết quả đánh giá model dựa trên ROC curve như sau:

ROC Curve for Logistic Regression



Area under the curve: 0.8113

Hiệu suất phân loại của mô hình đạt chỉ số đánh giá tốt > 0.8 . Hoàn toàn có thể tin tưởng.

5. Conclusion

Kết quả thu được tốt nhất sau cùng của bài toán phân nhãn này là:

- Đối với bài toán phân loại đa nhóm:
 - Tập data: chỉ gồm các biến `Health indicator`, xử lý imbalanced data bằng cách **undersampling về trung bình cho tập lớn, smote cho hai nhóm nhỏ hơn**.
 - Mô hình tốt nhất: Random Forest.
- Đối với bài toán phân loại nhị phân (Non-diabete vs Diabete):
 - Tập data: 10 biến có chỉ số tương quan, xử lý imbalanced data bằng cách **undersampling**.
 - Mô hình tốt nhất: Logistic Regression.